

# Đề xuất phương pháp đa tỷ lệ (MultiScale) để suy luận tải nhận thức từ bộ dữ liệu sinh lý CogLoad.

Nguyen Quoc Huy<sup>1</sup>, Do Nhu Tai<sup>2</sup>, Do Minh Quan<sup>1</sup>,  
Le Thi My Huong<sup>1</sup>, Tran Bui Ty Ty<sup>1</sup>

<sup>1</sup>Saigon University, VietNam.

<sup>2</sup>University of Economic HCMC, VietNam.

Contributing authors: [nqhuy@sgu.edu.vn](mailto:nqhuy@sgu.edu.vn); [dntai@sgu.edu.vn](mailto:dntai@sgu.edu.vn);  
[doquan19062004@gmail.com](mailto:doquan19062004@gmail.com); [myhuongtk2004@gmail.com](mailto:myhuongtk2004@gmail.com);  
[trabuityty1603@gmail.com](mailto:trabuityty1603@gmail.com);

## Tóm tắt nội dung

Trong xã hội thông tin hiện đại, con người luôn phải đối mặt với áp lực lớn lên khả năng nhận thức. Việc phát hiện sớm tải nhận thức không chỉ mang lại lợi ích trong các ứng dụng tương tác giữa con người và máy tính mà còn đóng góp vai trò quan trọng trong việc bảo vệ sức khỏe tinh thần, duy trì sự tập trung và nâng cao hiệu suất công việc. Nghiên cứu này tập trung vào phát hiện tải nhận thức thông qua các tính năng sinh lý được trích xuất từ phân đoạn 30 giây cuối của bộ dữ liệu thu được từ cuộc thi CogLoad@UbiComp2020. Bài báo sẽ phân tích các tín hiệu sinh lý như độ dẫn điện da (GSR), nhịp tim (HRV), nhịp thở (RR), và nhiệt độ cơ thể (Temperature). Kết hợp với phân tích đa thang đo (Multiscale Analysis) nhằm khai thác thông tin từ các mức độ tín hiệu khác nhau. Kết quả cho thấy XGBoost và SVM đạt hiệu suất cao nhất khi kết hợp dữ liệu đa tỷ lệ, với độ chính xác 69.95% và ROC 75%. Thực nghiệm cho thấy rằng các tín hiệu sinh lý này đóng vai trò quan trọng trong việc phân loại tải nhận thức (Cognitive Load), đồng thời áp dụng phân tích đa thang đo giúp cải thiện hiệu suất mô hình phân loại. Các thực nghiệm sử dụng các phương pháp đánh giá như độ chính xác, đường cong ROC để kiểm tra khả năng phân loại tải nhận thức từ các tín hiệu sinh lý.

**Keywords:** cognitive load, multi scale, machine learning, ensemble model.

link github: [https://github.com/TyTy7023/cogLoad\\_experiment](https://github.com/TyTy7023/cogLoad_experiment)

# 1 Introduction

Tải nhận thức (Cognitive Load) là khái niệm mô tả mức độ sử dụng tài nguyên nhận thức của con người như sự chú ý, trí nhớ làm việc, và khả năng ra quyết định trong quá trình thực hiện nhiệm vụ[1]. Đây là một khái niệm đa chiều, phản ánh sự tương tác giữa đặc điểm của nhiệm vụ, người thực hiện và các yêu cầu nhận thức cần thiết. Khi tải nhận thức vượt quá giới hạn trí nhớ làm việc, hiệu suất công việc giảm đáng kể, gây ra trạng thái căng thẳng hoặc lo lắng (overload). Ngược lại, khi tải nhận thức quá thấp, người dùng có thể rơi vào trạng thái nhàm chán.

Việc đo lường và quản lý tải nhận thức có vai trò quan trọng trong nhiều lĩnh vực. Trong tương tác người - máy tính (HCI), hiểu được trạng thái nhận thức của người dùng giúp tối ưu hóa trải nghiệm bằng cách tránh gián đoạn không cần thiết. Ví dụ, trong các hệ thống dạy học thông minh, việc hiểu CL có thể nâng cao kết quả học tập bằng cách cá nhân hóa nội dung giảng dạy theo nhu cầu của người học, điều này trở nên đặc biệt quan trọng trong bối cảnh đại dịch COVID-19 khi học trực tuyến trở nên phổ biến hơn bao giờ hết. Trong lĩnh vực trò chơi điện tử, các hệ thống dựa trên CL có thể cải thiện trải nghiệm người dùng bằng cách cân bằng giữa thử thách và sự thích thú. Tương tự, trong ngành y tế, việc giám sát CL của các chuyên gia y tế có thể giúp phát hiện tình trạng quá tải nhận thức và cung cấp hỗ trợ kịp thời để giảm thiểu sai sót do căng thẳng hoặc mệt mỏi.

Sự phát triển của công nghệ cảm biến và các thiết bị đeo tay thông minh đã mở ra cơ hội mới để đo lường tải nhận thức theo thời gian thực. Các thiết bị như Microsoft Band 2, vòng đeo tay GSR, hoặc cảm biến PPG không chỉ phổ biến mà còn không xâm lấn, cung cấp dữ liệu sinh lý như nhịp tim, đáp ứng da, hoặc nhịp thở. Nghiên cứu đã chỉ ra rằng các chỉ số sinh lý này có mối tương quan mạnh mẽ với trạng thái nhận thức. Bộ dữ liệu từ Cognitive Load Monitoring Challenge là một ví dụ điển hình, trong đó dữ liệu cảm biến được thu thập từ các đối tượng tham gia ở hai trạng thái: tải nhận thức cao và trạng thái nghỉ ngơi. Bộ dữ liệu được ghi lại với tần suất 1 Hz trong khoảng thời gian 30 giây, nhằm phân loại nhị phân trạng thái tải nhận thức cao và nghỉ ngơi[2].

Trong nghiên cứu này, chúng tôi đề xuất phương pháp đa tỷ lệ (multiscale) để suy luận tải nhận thức từ dữ liệu sinh lý, dựa trên bộ dữ liệu cung cấp trong cuộc thi. Ý tưởng chính là sử dụng các phân đoạn thời gian 30 giây cho mỗi đối tượng tham gia và tính toán 40 đặc trưng thống kê (trung bình, độ lệch chuẩn, giá trị tối đa, tối thiểu, v.v.) tại nhiều cấp độ tỷ lệ khác nhau. Với hai hướng tiếp cận chính: xây dựng mô hình đơn tỷ lệ (Single Scale) để đánh giá hiệu suất của từng tỷ lệ (Scale 0, Scale 1, Scale 2) riêng biệt; kết hợp các đặc trưng từ nhiều tỷ lệ (MultiScale), nhằm khai thác thông tin bổ sung từ các mức phân tích khác nhau của dữ liệu. Hiệu quả của các mô hình được đánh giá dựa trên các tiêu chí phổ biến trong bài toán phân loại nhị phân, bao gồm độ chính xác (Accuracy), đường cong ROC nhằm đảm bảo tính cân bằng, độ nhạy, và độ chính xác trong dự đoán trạng thái tải nhận thức. Phương pháp đa tỷ lệ (MultiScale) này không chỉ tận dụng được sự đa dạng trong dữ liệu mà còn kiểm chứng hiệu quả của các mô hình đơn và đa, mang lại một góc nhìn thực tế và toàn diện hơn trong việc suy luận tải nhận thức.

## 2 Related Works

Giám sát người dùng mở ra tiềm năng to lớn trong việc đo lường tải nhận thức một cách chính xác và theo thời gian thực. Thông tin này có thể được các hệ thống mà người dùng tương tác khai thác, từ đó cải thiện hiệu suất của họ thông qua các biện pháp hỗ trợ hoặc điều chỉnh phù hợp. Trong những năm gần đây, nhiều phương pháp đã được đề xuất để phát hiện tải nhận thức, và các giải pháp này sẽ được phân tích trong phần tiếp theo, bao gồm các triển khai dựa trên bộ dữ liệu của thử thách CogLoad@UbiComp2020.

Các nhà nghiên cứu đã điều tra tác động của tải trọng nhận thức (CL) đối với nhiều ứng dụng khác nhau. Một trong những lĩnh vực được quan tâm là học tập đa phương tiện và trực tuyến, là nơi các câu hỏi như cách xử lý thông tin của một cá nhân, học tập qua các phương pháp tiếp cận đa phương tiện, lựa chọn thiết kế giảng dạy phù hợp để tránh tải nhận thức[3], điều này nhằm cải thiện kết quả học tập.

**Bảng 1** Các nghiên cứu về tải nhận thức dựa trên tín hiệu sinh học

Nghiên Cứu	Tín Hiệu (HZ)	Độ Dài Cửa Sổ	Mô Hình	Độ Chính Xác
Anusha (2018) et al.	ECG(64), GSR(1000), ST(1000)	30-300	LDA, KNN, QDA, SVM	0.97
Pettersson (2020) et al.	EEG(512), ECG(1000)	45	SVM, RF, XGBoost	0.97
Fan (2020) et al.	ST(1), GSR(1), HR(1), RR(1)	360	SVM	0.80
Borisov (2021) et al.	ST(1), GSR(1), HR(1), RR(1)	30	Ensemble model	0.66
Tervonen (2021) et al.	ST(1), GSR(1), HR(1), RR(1)	30	XGBoost	0.67
Sang Gi Hong (2023) et al.	ST(1), GSR(1), HR(1), RR(1)	30	LightGBM	0.70

Trong Bảng 1, đã đề cập các nghiên cứu về các tín hiệu nhận thức. Anusha et al.[4] đã sử dụng tín hiệu hoạt động điện da (EDA), điện tâm đồ (ECG) và nhiệt độ da (ST) để theo dõi mức độ căng thẳng trong công việc. Họ đạt được độ chính xác tối đa 97,13% trong việc nhận diện căng thẳng công việc bằng cách kết hợp các tín hiệu EDA và ST trên các đoạn dữ liệu có độ dài 60 giây. Pettersson et al.[5] đã áp dụng tín hiệu điện cơ mắt (EOG) và điện tâm đồ (ECG) để phát hiện căng thẳng nhận thức trong bài kiểm tra căng thẳng cấp tính Maastricht. Kết quả cho thấy hiệu suất tốt nhất đạt được khi sử dụng kết hợp các đặc trưng của cả EOG và ECG, với các mô hình phân loại như máy vector hỗ trợ (SVM), rừng ngẫu nhiên (RF), và mô hình tăng cường gradient (XGBoost). Trong đó, SVM đạt được hiệu suất cao nhất khi phân loại giữa hai trạng thái thư giãn và căng thẳng. Fan et al.[6] đã nghiên cứu tác động của khối lượng công việc nhận thức đến tín hiệu EEG và ECG. Họ phân loại ba mức độ khối lượng công việc dựa trên các nhiệm vụ có độ khó khác nhau. Kết quả chỉ ra rằng các chỉ số ECG như mRR, RMSSD, HF\_norm và SampEn giảm đáng kể khi độ khó của nhiệm vụ tăng, trong khi LF\_norm và LF/HF lại tăng. Các đặc trưng này được giảm số chiều bằng phương pháp phân tích thành phần chính (PCA) và sử dụng làm đầu vào cho mô hình SVM, đạt được độ chính xác 80%. Các nghiên cứu [4], [5], [6] đạt được độ chính xác cao trong việc phát hiện tải nhận thức. Tuy nhiên, các nghiên cứu này yêu cầu tần số mẫu cao và không sử dụng các thiết bị đeo. Để khắc phục điều này, một cuộc thi về phát hiện tải nhận thức dựa trên thiết bị như

mô tả Hình 1 đã được tổ chức tại cuộc thi UbiComp2020, nhằm đề xuất và đánh giá các thuật toán nhận diện dựa trên thiết bị đeo.

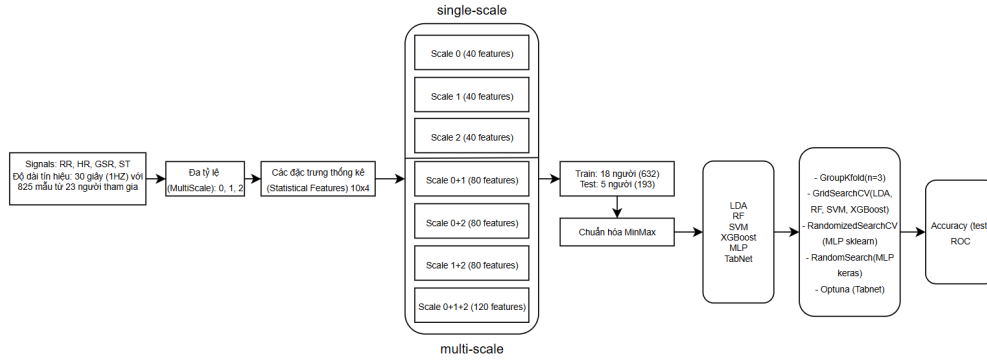


**Hình 1** Dây đeo tay Microsoft Band 2 được sử dụng để thu thập dữ liệu.

Gjoreski et al.[7] đã trình bày kết quả nhận diện tải trọng nhận thức thông qua sự kết hợp giữa phát hiện, lựa chọn đặc trưng và các bộ phân loại, áp dụng cho 13 đội tham gia cuộc thi CogLoad. Trong cuộc thi này, bộ dữ liệu CogLoad được sử dụng, bao gồm các tín hiệu RR, GSR, ST và HR được thu thập từ thiết bị đeo tay với 825 mẫu từ 23 người tham gia. Các đặc trưng bao gồm đặc trưng thủ công, đặc trưng thống kê (như trung bình, phương sai, độ lệch kurtosis, trung vị và tổng) và đặc trưng tần số (như tỷ lệ mật độ phổ công suất của HRV) được phân tích. Một số đội đã áp dụng các phương pháp như hệ số thông tin tối đa, tìm kiếm nổi ngược tuần tự và độ tập Gini để chọn ra các đặc trưng quan trọng nhất. Các bộ phân loại như SVM, RF, XGBoost và LightGBM được sử dụng trong phân tích, với mô hình tổ hợp (ensemble) cho kết quả phân loại tốt nhất. Borisov et al.[8] đạt kết quả cao nhất trong cuộc thi. Phương pháp của họ dựa trên việc trích xuất các đặc trưng thống kê như giá trị nhỏ nhất, lớn nhất, trung bình, độ lệch chuẩn, tổng và độ nghiêng từ các tín hiệu GSR, HR, RR và ST. Tải trọng nhận thức được nhận diện thông qua 8 mô hình tổ hợp LightGBM, đạt độ chính xác 66%. Tervonen et al.[9] đã thực hiện phân tích so sánh độ chính xác của các độ dài cửa sổ rất ngắn (<30 giây) trong nhận diện tải trọng nhận thức bằng dữ liệu CogLoad và thiết bị đeo. Họ trích xuất 157 đặc trưng, bao gồm các đặc trưng thống kê, đạo hàm bậc một và bậc hai, cũng như các đặc trưng HRV, làm đầu vào cho bộ phân loại XGBoost. Kết quả cho thấy cửa sổ 25 giây đạt độ chính xác cao nhất (67,6%), tương đương với các nghiên cứu trước đây sử dụng cùng bộ dữ liệu. Độ chính xác của mô hình giảm dần khi cửa sổ ngắn hơn, với độ chính xác thấp nhất (60,0%) được ghi nhận ở cửa sổ 5 giây. Sang Gi Hong et al.[10] đề xuất một thuật toán mới kết hợp lựa chọn đặc trưng và mô hình phân loại nhẹ như LightGBM để nhận diện tải nhận thức với độ chính xác cao, ngay cả khi sử dụng số lượng đặc trưng tối thiểu. Thuật toán đạt được độ chính xác 70.3% chỉ với 10 đặc trưng quan trọng được chọn, sử dụng bộ phân loại LightGBM.

### 3 Materials and Methods

Phương pháp được đề xuất đã trích xuất 40 đặc trưng thống kê từ mỗi tín hiệu sinh lý (RR, HR, GSR, ST) được ghi lại với tần số 1Hz trong 30 giây, thu được 825 mẫu từ 23 người tham gia. Phân tích đa tỷ lệ (multi-scale) được áp dụng ở ba mức (0, 1, 2), tạo ra các đặc trưng thống kê ở mỗi cấp độ. Tập đặc trưng bao gồm các đặc trưng đơn tỷ lệ (40 đặc trưng mỗi cấp) và các tổ hợp đa tỷ lệ (lên đến 120 đặc trưng). Dữ liệu được chia thành tập huấn luyện (18 người, 632 mẫu) và tập kiểm thử (5 người, 193 mẫu), sau đó được chuẩn hóa bằng Min-Max. Phân loại tải nhận thức được thực hiện bằng các mô hình LDA, RF, SVM, XGBoost, MLP và TabNet. LDA là một mô hình phân loại dựa trên việc giảm chiều dữ liệu, tối đa hóa sự khác biệt giữa các lớp. RF xây dựng nhiều cây quyết định và tổng hợp kết quả để tăng độ chính xác và ổn định. SVM sử dụng siêu phẳng để phân tách các lớp, hiệu quả trong việc xử lý dữ liệu có biên độ phân chia lớn. XGBoost là một thuật toán tăng cường dựa trên cây quyết định, nổi bật với khả năng xử lý dữ liệu lớn và giảm thiểu hiện tượng overfitting. MLP là một mạng nơ-ron tích hợp nhiều lớp ẩn, có khả năng học các mối quan hệ phức tạp trong dữ liệu. Trong khi đó, TabNet là một mô hình học sâu hiện đại, tối ưu hóa cho dữ liệu dạng bảng, sử dụng cơ chế attention để lựa chọn các đặc trưng quan trọng. Tinh chỉnh siêu tham số thông qua GridSearchCV(LDA, RF, SVM, XGB), RandomizedSearchCV, RandomSearch và Optuna, sử dụng phương pháp GroupKFold (n=3) để kiểm định chéo. Hiệu suất mô hình được đánh giá qua độ chính xác (accuracy) và đường cong ROC. Phương pháp được mô tả như Hình 2.



**Hình 2** Lưu đồ quy trình phân tích dữ liệu tải nhận thức

#### 3.1 CogLoad Data

Dữ liệu CogLoad là một tập dữ liệu thu thập từ các tín hiệu RR, HR, GSR và ST của 23 người tham gia. Các bài kiểm tra N-back (n= 2, 3) được thực hiện như các bài kiểm tra ước lượng tải nhận thức cùng với sáu nhiệm vụ nhận thức cơ bản (ECT). Sáu nhiệm vụ ECT bao gồm: hoàn thành hình Gestalt (Gestalt completion), tìm mẫu ẩn (Finding hidden pattern), tìm chữ A (Finding A's), so sánh số (Number

comparison), theo dõi đường (Pursuit test), và tìm chữ X rải rác (Scattered X's). Các bài kiểm tra ước lượng tải nhận thức được thực hiện với các mức độ khó tăng dần (dễ, trung bình, và khó).


Sau mỗi nhiệm vụ, tải nhận thức được đánh giá theo NASA-TLX. NASA-TLX là cách thức đánh giá công việc của người thực hiện nhiệm vụ được phát triển bởi NASA. Công cụ này đánh giá sáu khía cạnh khác nhau của tải nhận thức và thể chất mà một cá nhân trải nghiệm khi thực hiện một nhiệm vụ. Người tham gia được yêu cầu nghỉ ngơi trong 3 phút sau khi hoàn thành bảng câu hỏi, và các tín hiệu sinh lý được thu thập bằng một thiết bị đeo thương mại đeo trên cánh tay không thuận trong mỗi nhiệm vụ. Tổng cộng có 825 phiên ghi nhận, trong đó các khoảng thời gian nghỉ được gắn nhãn là "không tải"(0) và các khoảng thời gian thực hiện nhiệm vụ được gắn nhãn là "tải nhận thức"(1).

Tập dữ liệu được chia để huấn luyện và kiểm tra: 632 mẫu được ghi nhận từ 18 người tham gia được sử dụng để làm tập huấn luyện và 193 mẫu từ 5 người tham gia. Mỗi phiên ghi nhận bao gồm bốn tín hiệu 30 giây, và tín hiệu được cung cấp với tần số lấy mẫu 1Hz.

### 3.2 Trích xuất đặc trưng đa tỷ lệ (Multi-Scale Feature Extraction)

Các thống kê đặc trưng cung cấp thông tin quan trọng về dữ liệu. Trung bình cộng đo giá trị trung bình, độ lệch chuẩn đo mức độ phân tán quanh giá trị trung bình, và độ lệch (skewness) cho biết sự lệch của phân phối. Độ nhọn (kurtosis) đo độ nhọn của phân phối. Trung bình cộng của đạo hàm bậc nhất và bậc hai giúp hiểu sự thay đổi và xu hướng của dữ liệu. Độ khác biệt của dữ liệu (diff2) đánh giá sự thay đổi không đều, phân vị 25 và 75 đo sự phân bố dữ liệu, và độ lệch phân vị phản ánh sự phân tán giữa chúng. Phạm vi đo sự khác biệt giữa giá trị lớn nhất và nhỏ nhất trong dữ liệu.

Phân tích đa tỷ lệ (multi-scale) là phương pháp trích xuất đặc trưng ở nhiều cấp độ khác nhau của tín hiệu sinh lý, nhằm nắm bắt các biến động xảy ra ở cả ngắn hạn và dài hạn. Trong nghiên cứu này, các tín hiệu RR, HR, GSR và ST được phân tích ở ba mức độ. Với các đơn tỷ lệ ta phân tích như sau:



**Hình 3** Phân tích tín hiệu đơn tỷ lệ (Single-Scale Signal Analysis) lần lượt là Scale 0, 1, 2.

- **Scale 0:** Đặc trưng trích xuất trực tiếp từ tín hiệu gốc (10x4 đặc trưng).

- **Scale 1:** Tín hiệu được chia đôi với phân đoạn 30 giây ta chia thành 15 giây mỗi đoạn, trích xuất đặc trưng từ mỗi phần và tính trung bình (10x4 đặc trưng).
- **Scale 2:** Tín hiệu được chia thành bốn phần với tín hiệu 30 giây, trích xuất đặc trưng từ mỗi phần và tính trung bình (10x4 đặc trưng).

Đối với đa tỷ lệ (multi scale), mỗi cấp độ cung cấp 10x4 đặc trưng thống kê, bao gồm giá trị trung bình, độ lệch chuẩn, và các thước đo phân bố. Để tăng cường độ chính xác, các đặc trưng từ nhiều cấp độ được kết hợp, tạo thành các tổ hợp như:

- Scale 0 + 1 (80 đặc trưng)
- Scale 0 + 2 (80 đặc trưng)
- Scale 1 + 2 (80 đặc trưng)
- Scale 0 + 1 + 2 (120 đặc trưng)

Việc tổ hợp giúp mô hình học được nhiều thông tin hơn từ tín hiệu ở các góc độ và tần suất khác nhau, cải thiện khả năng nhận diện tải nhận thức. Các đặc trưng sau khi trích xuất được chuẩn hóa bằng phương pháp Min-Max trước khi đưa vào các mô hình phân loại.

## 4 Results

Hướng tiếp cận đầu tiên là đơn tỷ lệ được mô tả trong Bảng 2, trong đó dữ liệu được phân chia thành từng tỷ lệ riêng biệt (Scale 0, Scale 1, Scale 2) để đánh giá hiệu suất nhận dạng tải nhận thức của các mô hình. Kết quả cho thấy mô hình LDA và SVM có độ chính xác và ROC cao nhất ở hầu hết các tỷ lệ, với độ chính xác cao nhất là 0.6839 và ROC đạt 0.74 ở Scale 0. Trong khi đó, mô hình TabNet có hiệu suất thấp nhất với độ chính xác chỉ 0.5130 và ROC 0.54 ở Scale 2. Các mô hình như RF và SVM cho kết quả khá ổn định giữa các tỷ lệ khác nhau, còn mô hình XGB cho thấy hiệu suất giảm nhẹ khi chuyển từ Scale 0 sang Scale 2. Nhìn chung, hướng tiếp cận đơn tỷ lệ phù hợp cho các bài toán có sự khác biệt rõ ràng giữa các tỷ lệ, trong đó SVM và RF là những mô hình đáng tin cậy để nhận dạng tải nhận thức khi sử dụng dữ liệu đơn tỷ lệ.

Model	Scale 0		Scale 1		Scale 2	
	Accuracy	ROC	Accuracy	ROC	Accuracy	ROC
LDA	0.6839	0.73	0.6528	0.74	0.6321	0.72
RF	0.6632	0.74	0.6684	0.74	0.6218	0.68
SVM	0.6736	0.74	0.6477	0.73	0.6684	0.72
XGB	0.6269	0.66	0.6528	0.71	0.6114	0.67
TabNet	0.5285	0.49	0.5233	0.53	0.5130	0.54
MLP(keras)	0.5907	0.73	0.6580	0.73	0.6528	0.71
MLP(sklearn)	0.6373	0.68	0.6373	0.72	0.6477	0.71

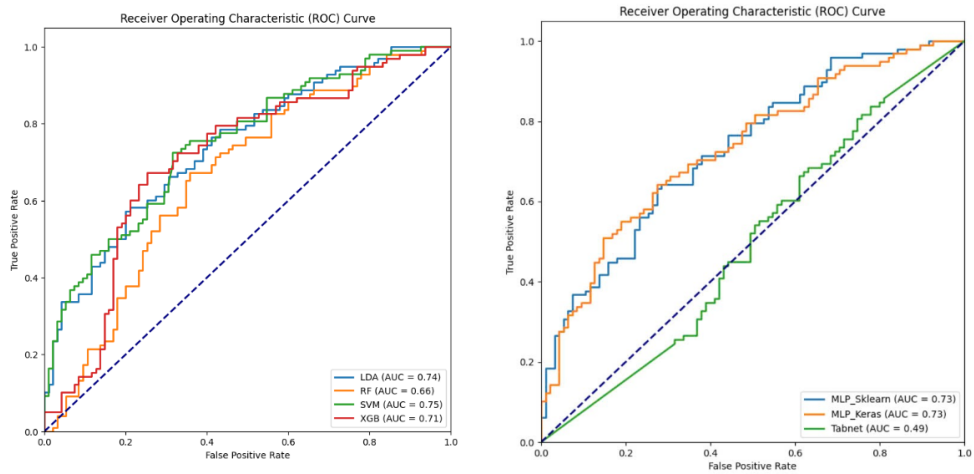
**Bảng 2** Kết quả nhận dạng tải nhận thức với hướng tiếp cận đơn tỷ lệ.

Hướng tiếp cận thứ hai là đa tỷ lệ được mô tả trong Bảng 3, trong đó dữ liệu từ nhiều tỷ lệ được kết hợp (Scale 0+1, Scale 0+2, Scale 1+2 và Scale 0+1+2) để khai

thác thông tin từ sự đa dạng của dữ liệu. Kết quả cho thấy mô hình XGB và SVM đạt độ chính xác cao nhất là 0.6995 với ROC của XGB đạt 0.75 Scale 0+1+2, đường cong ROC được mô tả ở Hình 4. Ngược lại, mô hình TabNet tiếp tục có hiệu suất thấp nhất với độ chính xác chỉ 0.4974 và ROC 0.43. Các mô hình như LDA và RF duy trì hiệu suất ổn định với độ chính xác và ROC dao động trong khoảng 0.65–0.68. Như vậy, việc kết hợp nhiều tỷ lệ đã cải thiện hiệu suất nhận dạng so với phân tích riêng lẻ từng tỷ lệ, và mô hình XGB cho thấy khả năng xử lý hiệu quả dữ liệu đa tỷ lệ, đặc biệt ở các tổ hợp tỷ lệ phức tạp.

Model	Scale 0+1		Scale 0+2		Scale 1+2		Scale 0+1+2	
	Accuracy	ROC	Accuracy	ROC	Accuracy	ROC	Accuracy	ROC
LDA	0.6736	0.74	0.6684	0.74	0.6632	0.74	0.6684	0.74
RF	0.6528	0.72	0.6528	0.70	0.6062	0.65	0.6477	0.66
SVM	0.6839	0.73	0.6736	0.71	0.6425	0.72	<b>0.6995</b>	0.75
XGB	0.6528	0.71	0.5492	0.62	0.6632	0.68	<b>0.6995</b>	0.71
TabNet	0.5337	0.45	0.4974	0.48	0.5130	0.51	0.43	0.49
MLP(keras)	0.6632	0.72	0.6632	0.72	0.6477	0.73	0.6632	0.73
MLP(sklearn)	0.6632	0.72	0.6113	0.69	0.6166	0.69	0.6373	0.73

**Bảng 3** Kết quả nhận dạng tải nhận thức với hướng tiếp cận đa tỷ lệ.



**Hình 4** Đường cong ROC ở Scale 0+1+2

## 5 Conclusion

Nghiên cứu này đã đề xuất và triển khai phương pháp phân tích đa tỷ lệ (MultiScale) để suy luận tải nhận thức từ bộ dữ liệu sinh lý CogLoad. Các đặc trưng



thống kê được trích xuất từ các tín hiệu sinh lý như độ dẫn điện da (GSR), nhịp tim (HR), nhịp thở (RR) và nhiệt độ (Temp) đã chứng minh hiệu quả trong việc phân loại trạng thái tải nhận thức (Task) và nghỉ ngơi (Rest).

Phương pháp phân tích đa tỷ lệ đã tận dụng thông tin từ nhiều cấp độ tín hiệu, giúp cải thiện độ chính xác và khả năng tổng quát của mô hình phân loại. Kết quả thực nghiệm cho thấy mô hình XGBoost và SVM đạt hiệu suất cao nhất khi kết hợp dữ liệu từ nhiều tỷ lệ, với độ chính xác lên đến 69.95% và ROC đạt 0.75. Các phương pháp khác như LDA và RF cũng duy trì hiệu suất ổn định, trong khi TabNet cho thấy hiệu suất thấp hơn trong cả hai hướng tiếp cận đơn tỷ lệ và đa tỷ lệ.

So sánh hai phương pháp, tiếp cận đơn tỷ lệ phù hợp để phân tích chi tiết từng mức dữ liệu, trong khi tiếp cận đa tỷ lệ khai thác sự đa dạng thông tin từ nhiều cấp độ, cải thiện đáng kể hiệu suất phân loại. Điều này chứng minh rằng phương pháp đa tỷ lệ có khả năng giải quyết các bài toán phân loại phức tạp và biến đổi dữ liệu tốt hơn so với phương pháp đơn lẻ.

Nghiên cứu này đặt nền tảng cho các ứng dụng theo dõi tải nhận thức trong thực tế, đặc biệt trong các lĩnh vực tương tác người-máy, giám sát sức khỏe và đào tạo thông minh. Trong tương lai, chúng tôi sẽ mở rộng bộ dữ liệu và áp dụng các thuật toán học sâu để tiếp tục cải thiện hiệu suất và tính ứng dụng của hệ thống.

## Tài liệu

- [1] Sweller, J. (2011), *Cognitive load theory*. In Psychology of learning and motivation (Vol. 55, pp. 37–76). Elsevier. International joint conference on pervasive, T.A., ubiquitous computing. (2020). Ubicomp2020. <https://doi.org/10.1016/B978-0-12-387691-1.00002-8>.
- [2] Xiling Li và Martine De Cock, *Cognitive Load Detection from Wrist Band Sensors*. UbiComp/ISWC '20 Adjunct, 2020 <https://doi.org/10.1145/3410530.3414428>.
- [3] Richard E. Mayer (2014), *Cognitive Theory of Multimedia*. <https://doi.org/10.1017/CBO9781139547369.005>
- [4] Anusha, A. S., Jose, J., Preejith, S. P., Jayaraj, J., & Mohanasankar, S. (2018), *Physiological signal-based work stress detection using unobtrusive sensors*. Biomedical Physics & Engineering Express, 4(6), 065001. <https://doi.org/10.1088/2057-1976/aadbd4>
- [5] Pettersson, K., Tervonen, J., Närviäinen, J., Henttonen, P., Määtänen, I., & Mäntyjärvi, J. (2020), *Selecting feature sets and comparing classification methods for cognitive state estimation*. In Proceedings of the IEEE 20th International Conference on Bioinformatics and Bioengineering (BIBE 2020) (pp. 683–690). <https://ieeexplore.ieee.org/document/9288104>.
- [6] Fan, X., Zhao, C., & Zhang, W. (2020), *Assessment of mental workload based on multi-physiological signals*. Technology and Health Care. <https://doi.org/10.3233/THC-209008>.

- [7] M. Gjoreski et al, *ognitive Load Monitoring With Wearables–Lessons Learned From a Machine Learning Challenge*. In IEEE Access, vol. 9, pp. 103325- 103336, 2021. [doi:10.1109/9466833/3093216](https://doi.org/10.1109/9466833/3093216).
- [8] Borisov, V., Kasneci, E., & Kasneci, G. (2021), *Robust cognitive load detection from wrist-band sensors*. Computers in Human Behavior Reports, 4, 100116. <https://doi.org/10.1016/j.chbr.2021.100116>.
- [9] Tervonen, J., Pettersson, K., & Mäntyjärvi, J. (2021), *ultra-short window length and feature importance analysis for cognitive load detection from wearable sensors*. Electronics, 10(5), 613. <https://doi.org/10.3390/electronics10050613>.
- [10] Kim, J.-K., Lee, K., & Hong, S. G. (2023), *Cognitive load recognition based on T-test and SHAP from wristband sensors*. Human-centric Computing and Information Sciences, 13, Article 27. <https://doi.org/10.22967/HGIS.2023.13.027>.